머신러닝 1장
(생선 분류 문제)

혼자 공부하는 머신러닝+딥러닝

목차

개념 정리

- 인공지능(Artificial Intelligence)이란?
  - 사람처럼 학습, 추론할 수 있는 지능을 가진 컴퓨터 시스템
  - 80년 역사(1943년 ~)

- 인공지능 vs 기계학습 vs 딥러닝

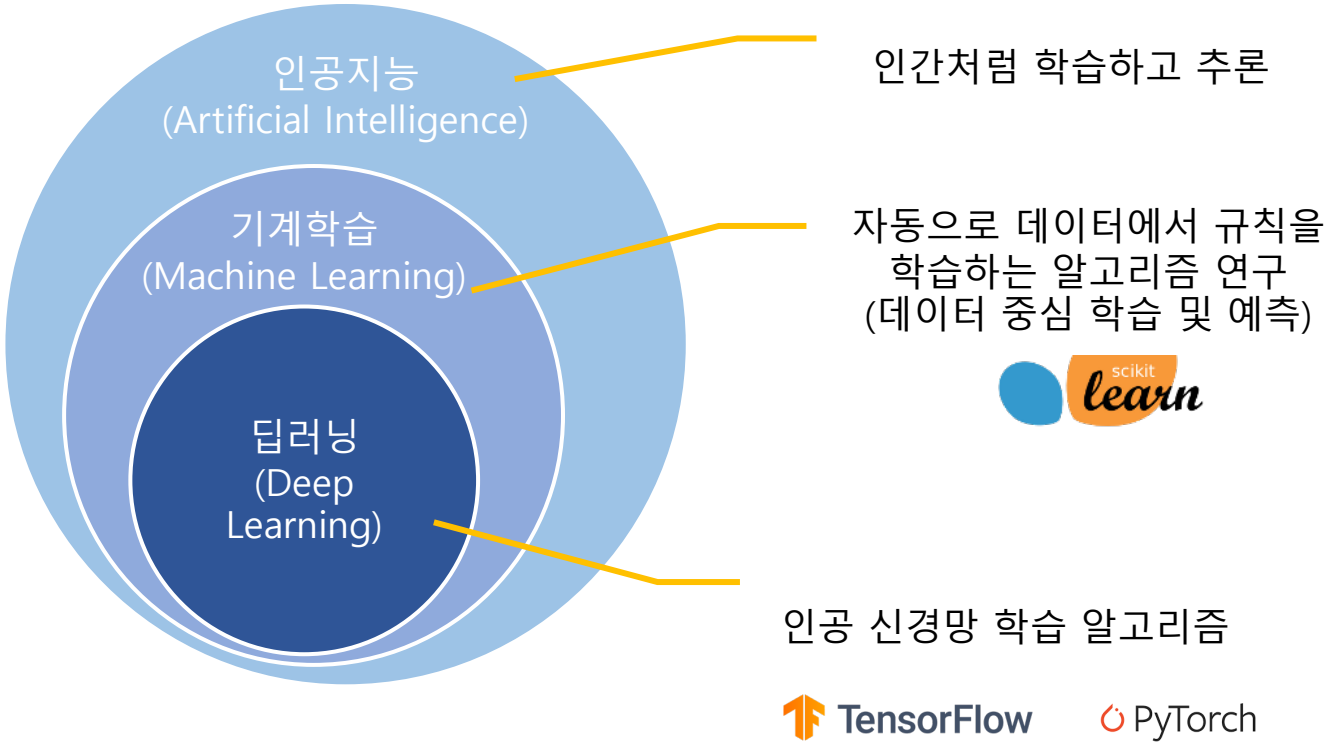

생선 분류 문제

- 생선 마켓에서 도미와 빙어 분류 문제
  - 전통적인 프로그램
    - 다양한 생선 종류 (정해진 기준대로 분류)
    - 길이만으로 분류하기 어려움

```
if fish_length >= 30:
    print("도미")
```

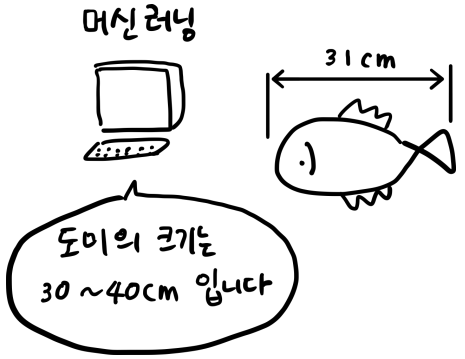

  - 첫 번째 머신 러닝 프로그램
    - 스스로 기준을 찾고, 기준을 이용하여 생선을 분류
    - 기준 설정
      - 생선의 길이와 무게로 비교

도미(bream)

빙어(smelt)

생선 데이터셋: https://www.kaggle.com/datasets/aungpyaeap/fish-market

도미 데이터 준비

- 도미(bream) 데이터 활용:
  - 총 35마리의 데이터
  - 길이와 무게를 이용한 산점도(scatter plot) 그리기

```
bream_length = [25.4, 26.3, 26.5, 29.0, 29.0, 29.7, 29.7, 30.0, 30.0, 30.7, 31.0,
                31.0, 31.5, 32.0, 32.0, 32.0, 33.0, 33.0, 33.5, 33.5, 34.0, 34.0,
                34.5, 35.0, 35.0, 35.0, 35.0, 36.0, 36.0, 37.0, 38.5, 38.5, 39.5,
                41.0, 41.0]

bream_weight = [242.0, 290.0, 340.0, 363.0, 430.0, 450.0, 500.0, 390.0, 450.0, 500.0,
                475.0, 500.0, 500.0, 340.0, 600.0, 600.0, 700.0, 700.0, 610.0, 650.0,
                575.0, 685.0, 620.0, 680.0, 700.0, 725.0, 720.0, 714.0, 850.0, 1000.0,
                920.0, 955.0, 925.0, 975.0, 950.0]
```

```
import matplotlib.pyplot as plt

plt.scatter(bream_length, bream_weight)
plt.xlabel('bream length') # x축은 길이
plt.ylabel('bream weight') # y축은 무게
plt.show()
```

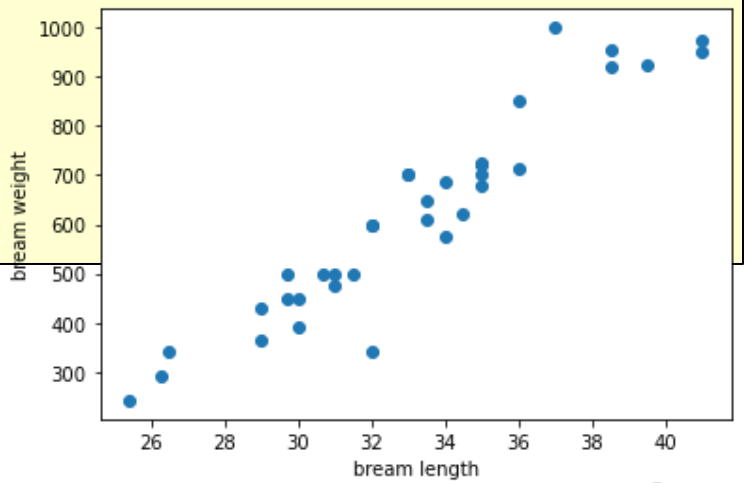

- 산점도 그래프
  - 일직선에 가까운 선형(linear) 그래프

빙어 데이터와 도미 데이터 비교

- 빙어(smelt) 데이터
  - 총 14마리의 빙어 데이터

```
smelt_length = [9.8, 10.5, 10.6, 11.0, 11.2, 11.3, 11.8, 11.8, 12.0, 12.2,
                12.4, 13.0, 14.3, 15.0]
smelt_weight = [6.7, 7.5, 7.0, 9.7, 9.8, 8.7, 10.0, 9.9, 9.8, 12.2, 13.4,
                12.2, 19.7, 19.9]
```

  - 도미 데이터와 빙어 데이터 비교 (산점도)

```
plt.scatter(bream_length, bream_weight, label='bream')
plt.scatter(smelt_length, smelt_weight, label='smelt')
plt.xlabel('length')
plt.ylabel('weight')
plt.legend()
plt.show()
```

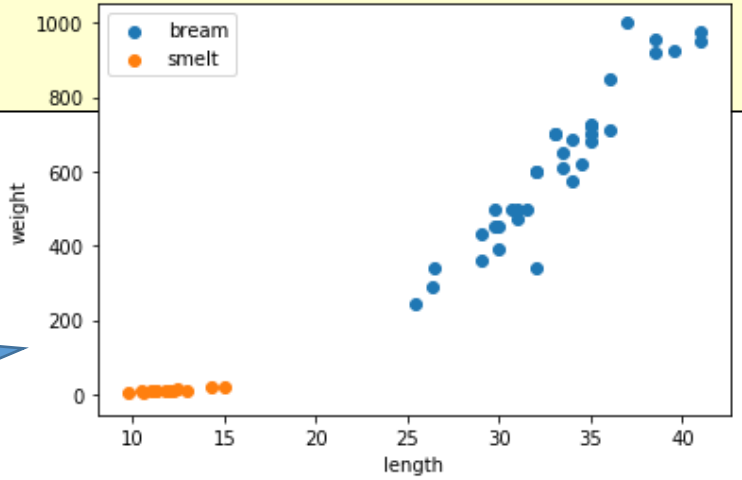

빙어의 크기와 무게가
도미와 많은 차이를 보임

2차원 리스트로 데이터 변형

- 도미 데이터와 빙어 데이터 합치기

```
length = bream_length + smelt_length
weight = bream_weight + smelt_weight
```

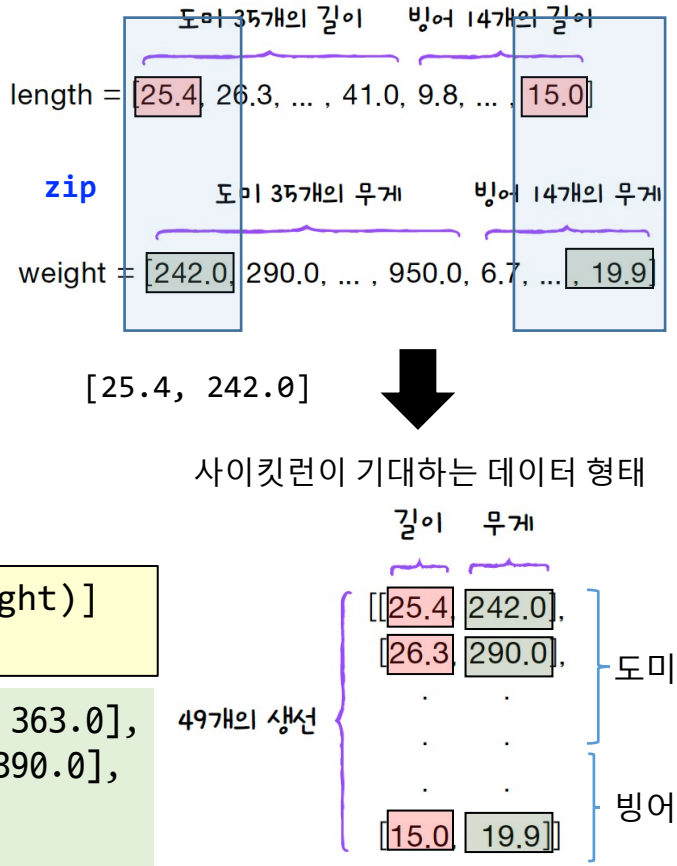

- 데이터 변형
  - 1차원 리스트 2개를 2차원 리스트로 변경
  - zip(length, weight)함수를 이용
    - 길이와 무게를 하나의 쌍으로 묶음

```
fish_data = [[l, w] for l, w in zip(length, weight)]
print(fish_data)
```

```
[[25.4, 242.0], [26.3, 290.0], [26.5, 340.0], [29.0, 363.0],
[29.0, 430.0], [29.7, 450.0], [29.7, 500.0], [30.0, 390.0],
[30.0, 450.0],
...
[14.3, 19.7], [15.0, 19.9]]
```

정답 데이터 준비

- 정답 데이터(`fish_target`) 준비
  - 생선의 길이와 무게를 이용하여 도미(1)와 빙어(0)를 구분
    - 찾고자 하는 데이터(도미)를 1로 설정
  - 원본 데이터:
    - 도미 데이터: 35마리의 데이터를 1로 설정
    - 빙어 데이터: 14마리의 데이터를 0으로 설정

```
fish_target = [1] * 35 + [0] * 14
print(fish_target)
```

```
[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0]
```

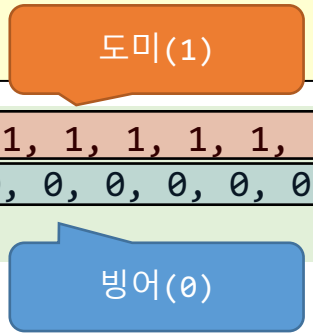

k-최근접 알고리즘 개요

- k-최근접 알고리즘(k-Nearest Neighbor, kNN)
  - 가장 간단한 분류 알고리즘 (classification)
  - "비슷한 특성을 가진 데이터는 비슷한 범주에 속한다"는 가정
  - 주변의 가장 가까운 k개의 데이터를 보고, 데이터가 속할 그룹을 판단

  - 단점
    - 모든 데이터를 가지고 있어야 됨
    - 많은 메모리 소모, 거리 계산에 많은 시간이 소요

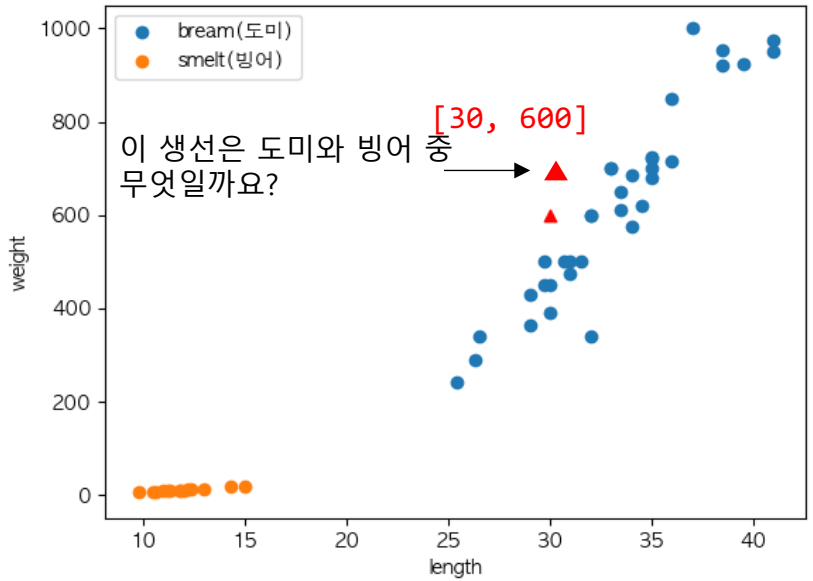

k-최근접 알고리즘 적용 과정

- kNN 모델 생성
  - KNeighborClassifier(n_ngighbors, …) 객체 생성
  - 기본 이웃의 개수: n_neighbors=5

```
from sklearn.neighbors import KNeighborsClassifier
kn = KNeighborsClassifier()
```

- 모델 훈련(학습)
  - fit(Training data, Target values) 함수
  - fish_data와 fish_target을 이용하여 모델 훈련

```
kn.fit(fish_data, fish_target)
```

- 모델 평가: score() 함수
  - score(Test samples, Target values): 정확도의 평균값 리턴

```
kn.score(fish_data, fish_target)
```

- 새로운 데이터를 활용한 결과 예측: predict(X)

```
kn.predict([[30, 600]]) # class label 리턴(0, 1)
```

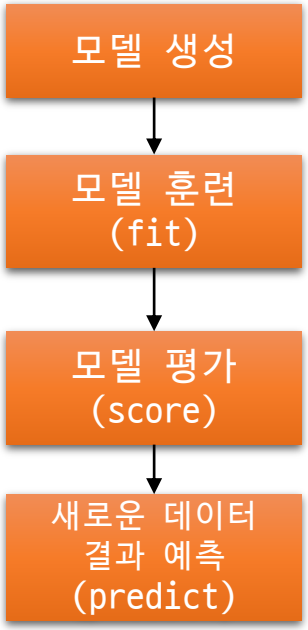

predict(x)
-x: 2차원 리스트 형태

scikit-learn API https://scikit-learn.org/stable/modules/classes.html

소스 코드 (chap01-3.py) #1

```
import matplotlib.pyplot as plt
import platform

bream_length = [25.4, 26.3, 26.5, 29.0, 29.0, 29.7, 29.7, 30.0, 30.0, 30.7,
                31.0, 31.0, 31.5, 32.0, 32.0, 32.0, 33.0, 33.0, 33.5, 33.5,
                34.0, 34.0, 34.5, 35.0, 35.0, 35.0, 35.0, 36.0, 36.0, 37.0,
                38.5, 38.5, 39.5, 41.0, 41.0]
bream_weight = [242.0, 290.0, 340.0, 363.0, 430.0, 450.0, 500.0, 390.0, 450.0, 500.0,
                475.0, 500.0, 500.0, 340.0, 600.0, 600.0, 700.0, 700.0, 610.0, 650.0,
                575.0, 685.0, 620.0, 680.0, 700.0, 725.0, 720.0, 714.0, 850.0, 1000.0,
                920.0, 955.0, 925.0, 975.0, 950.0]

smelt_length = [9.8, 10.5, 10.6, 11.0, 11.2, 11.3, 11.8, 11.8, 12.0, 12.2,
                12.4, 13.0, 14.3, 15.0]
smelt_weight = [6.7, 7.5, 7.0, 9.7, 9.8, 8.7, 10.0, 9.9, 9.8, 12.2,
                13.4, 12.2, 19.7, 19.9]

length = bream_length + smelt_length
weight = bream_weight + smelt_weight

fish_data = [[l, w] for l, w in zip(length, weight)] # 훈련 데이터 생성
print(fish_data)

fish_target = [1] * 35 + [0] * 14 # 정답 데이터(target) 생성
#print(fish_target)
```

소스 코드 (chap01-3.py) #2

```
from sklearn.neighbors import KNeighborsClassifier

kn = KNeighborsClassifier()    # 모델 생성
kn.fit(fish_data, fish_target) # 모델 훈련

print("score: ", kn.score(fish_data, fish_target)) # 모델 평가
print("predict: ", kn.predict([[30, 600]])) # 정답 예측, 리턴값: class label(분류값: 0, 1)

if platform.system() == 'Windows':
    plt.rc('font', family='Malgun Gothic')
elif platform.system() == 'Darwin': # MacOS
    plt.rc('font', family='AppleGothic')
else:
    plt.rc('font', family='AppleGothic')

plt.scatter(bream_length, bream_weight, label='bream(도미)')
plt.scatter(smelt_length, smelt_weight, label='smelt(빙
plt.scatter(30, 600, marker='^', color='red')
plt.xlabel('length')
plt.ylabel('weight')
plt.legend()
plt.show()
```

```
score:  1.0 # 100% 정확
predict:  [1] # (30cm, 600g)의 생선: 도미로 예측
```

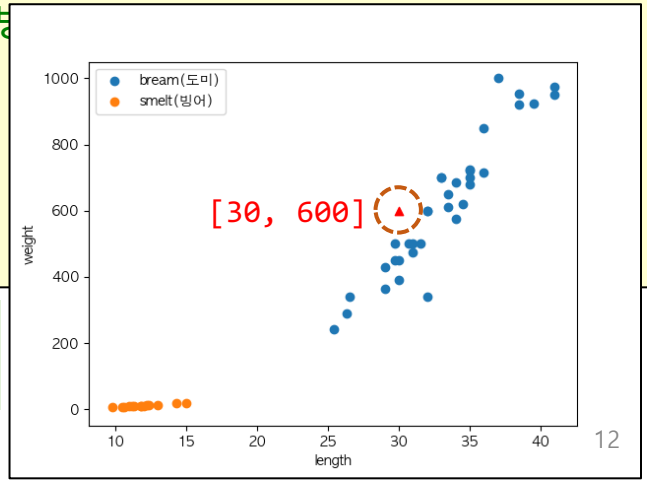

k-최근접 알고리즘 속성

- _fit_X 속성
  - 훈련 데이터를 모두 가짐(fish_data)

```
print(kn._fit_X)
```

```
[[ 25.4 242. ]
 [ 26.3 290. ]
 [ 26.5 340. ]
 [ 29. 363. ]
     . . .
 [13. 12.2]
 [14.3 19.7]
 [15. 19.9]]
```

- _y 속성
  - fish_target을 가짐

```
print(kn._y)
```

```
[1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0]
```

k-최근접 알고리즘 속성

- n_neighbors 값 변경(49)

```
kn49 = KNeighborsClassifier(n_neighbors=49)
```

```
kn49.fit(fish_data, fish_target)
kn49.score(fish_data, fish_target)
```

```
0.7142857142857143
```

  - fish_data의 49개 중에 도미가 35개를 차지함

- 35/49의 결과와 동일

```
print(35/49)
```

```
0.7142857142857143
```

마무리 정리

- 정확도
  - 정확한 답을 맞춘 백분율 (0 ~ 1사이의 값)
  - 정확도 = $\frac{\text{정확히 맞힌 개수}}{\text{전체 데이터 개수}}$
- KNeighborClassifier()
  - k-최근접 이웃 분류 모델
  - n_neighbors 변수에 이웃의 개수를 지정 (default값=5)
- fit(특성데이터, 정답데이터)
  - 모델 훈련
- score(특성데이터, 정답데이터)
  - 모델의 성능 측정
- predict(특성데이터)
  - 모델 결과 예측

Python 참고 자료

zip() 함수

- zip() 함수
  - 2개 이상의 리스트를 받아서 하나로 묶음 (튜플 형태로 묶음)

```
numbers = [ 1,  2,  3,  4 ]
letters = ['A', 'B', 'C', 'D']
for pair in zip(numbers, letters):  # 하나로 묶어서 출력
    print(pair)

pair = list(zip(numbers, letters))
print(pair)

n1, l1 = zip(*pair) # zip 해제 : *사용
print(n1, l1)
```

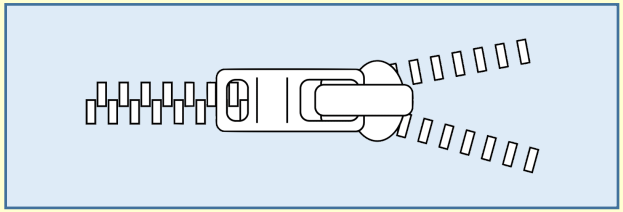

```
(1, 'A')
(2, 'B')
(3, 'C')
(4, 'D')
[(1, 'A'), (2, 'B'), (3, 'C'), (4, 'D')]
(1, 2, 3, 4) ('A', 'B', 'C', 'D')
```

Questions?